

CAHIER DES CHARGES

Projet Data Visualisation

Projet 3

Performance Opérationnelle Des Compagnies Aériennes Américaines

Source de données :

Airline Delay and Cancellation Data (2009-2018) | Kaggle | ~68 millions de vols | Source BTS/DOT
kaggle.com/datasets/yuanyuwendymu/airline-delay-and-cancellation-data-2009-2018

1. Contexte General et Positionnement Metier

1.1 La décennie 2009-2018 : transformation structurelle de l'aviation américaine

La période 2009-2018 est la plus transformatrice de l'histoire récente de l'aviation civile américaine. Elle s'ouvre sur les séquelles de la crise financière de 2008 qui a obligé plusieurs transporteurs à restructurer massivement leurs opérations, et se conclut sur un secteur consolidé, rentable et confronté à de nouveaux défis de capacité. Quatre événements majeurs structurent cette décennie et constituent le fil conducteur métier du projet :

Période	Évènement structurant	Impact métier à mesurer
2009-2010	Crise financière — contraction du trafic, faillites (Mesa, Pinnacle)	Baisse de volume, ajustements OTP, montée des annulations
2010-2013	Vague de mega-fusions : United+Continental (2010), Southwest+AirTran (2011), American+US Airways (2013)	Dégradation transitoire de l'OTP pendant l'intégration, rebranding des codes IATA
2014-2016	Stabilisation post-fusions, chute du prix du kérosène (-50%)	Hausse de la rentabilité, réinvestissement, amélioration OTP sur la période
2017-2018	Contrainte de capacité aéroportuaire, saturation des hubs, tensions SAV	Remonter des retards NAS, pression sur les hubs Chicago, New York, Dallas

Votre mission : produire un observatoire comparatif de la performance opérationnelle sur 10 ans, permettant de benchmarker les compagnies, d'identifier les causes de sous-performance structurelle et d'évaluer l'impact des événements sectoriels sur la ponctualité.

Spécificité technique centrale : Ce projet demande de savoir fusionner plusieurs fichiers annuels. Il faut assembler 10 fichiers CSV distincts (de 2009.csv à 2018.csv) en gardant une trace de l'année pour chaque donnée.

1.2 Les quatre axes d'analyse métier

AX1	Benchmarking OTP et Ranking des compagnies sur 10 ans
AX2	Décomposition et analyse des 7 causes de retard par transporteur
AX3	Impact des fusions et de la consolidation sectorielle sur la performance
AX4	Saisonnalité, cycles économiques et patterns de ponctualité long terme

2. Description du Dataset

2.1 Source, accès et structure

La dataset est produite par le Bureau of Transportation Statistics (BTS), l'autorité statistique officielle du Département of Transportation américain. Il recense l'intégralité des vols domestiques des compagnies déclarantes (seuil > 0.5% des revenus domestiques) entre janvier 2009 et décembre 2018, soit 10 années complètes de données.

Le lien de téléchargement : [Airline Delay and Cancellation Data, 2009 - 2018](#)

2.2 Volumétrie

Caracteristique	Valeur
Volume total	~65 a 68 millions de vols domestiques USA
Période	Janvier 2009 - Décembre 2018 (10 années complètes)
Structure	10 fichiers CSV annuels indépendants (schéma BTS standard)
Nombre de colonnes	28 à 32 colonnes selon année
Compagnies couvertes	~17 à 20 compagnies selon année
Aéroports couverts	~350 aéroports domestiques USA
Taille totale non compressée	~6.5 à 7 GB (CSV) ~1.8 GB (Parquet ZSTD)
Stratégie de dev recommandée	Travailler sur 2015.csv (année complète stable, ~5.8M lignes) pour le prototypage

2.3 Description des colonnes

Noms de colonnes selon la version BTS la plus courante du dataset Kaggle. Vérifier les noms exacts de chaque fichier annuel à l'ingestion.

Colonne BTS	Type	Description métier	Points de vigilance
FL_DATE	Date	Date complète du vol (YYYY-MM-DD)	Source principale de toute la temporalité - parsing obligatoire
YEAR	Integer	Année du vol	Déjà disponible - ne pas recalculer
QUARTER	Integer	Trimestre (1-4)	Déjà fourni - exploiter directement
MONTH	Integer	Mois (1-12)	Déjà fourni - clé de la saisonnalité
DAY_OF_MONTH	Integer	Jour du mois (1-31)	Pour analyses journalières fines
DAY_OF_WEEK	Integer	Jour de semaine (1=Lundi, 7=Dimanche)	Clé de l'analyse hebdomadaire
OP_UNIQUE_CARRIER	String	Code IATA operateur réel (ex: DL, AA, WN)	ATTENTION : les codes changent après les fusions - table de correspondance obligatoire
TAIL_NUM	String	Numéro de queue de l'appareil	Permet de suivre un avion - analyse LATE_AIRCRAFT
OP_CARRIER_FL_NUM	Integer	Numéro de vol	Cle d'identification avec ORIGIN + FL_DATE
ORIGIN	String	Code IATA aéroport départ	Jointure avec référentiel aéroports BTS
ORIGIN_CITY_NAME	String	Ville et Etat départ (ex: Chicago, IL)	Format 'City, ST' - extraction Etat par split
ORIGIN_STATE_ABR	String	Code Etat départ (ex: IL, TX, CA)	Déjà disponible - clé pour vues par Etat
DEST	String	Code IATA aéroport arrivée	Même logique qu'ORIGIN

Colonne BTS	Type	Description metier	Points de vigilance
DEST_CITY_NAME	String	Ville et Etat arrivée	Même logique qu'ORIGIN_CITY_NAME
DEST_STATE_ABR	String	Code Etat arrivée	Même logique qu'ORIGIN_STATE_ABR
CRS_DEP_TIME	Integer	Heure départ programmée (HHMM)	Ex: 1435 = 14h35 - conversion timedelta requise
DEP_TIME	Float	Heure départ réelle (HHMM)	NaN si annule
DEP_DELAY	Float	Retard départ en minutes (négatif = avance)	NULL si annule - KPI départ
DEP_DELAY_NEW	Float	Retard depart en minutes (0 si avance, sinon = DEP_DELAY)	Version 'clamped' utile pour moyennes sans biais d'avance
DEP_DEL15	Float (0/1)	Indicateur retard départ > 15 min	Binary - OTP départ direct
TAXI_OUT	Float	Roulage avant décollage (minutes)	Indicateur congestion aéroport départ
WHEELS_OFF	Float	Heure décollage réel (HHMM)	Calcul du retard réel de décollage
WHEELS_ON	Float	Heure atterrissage reel (HHMM)	Calcul du temps en vol réel
TAXI_IN	Float	Roulage après atterrissage (minutes)	Indicateur congestion aéroport arrivée
CRS_ARR_TIME	Integer	Heure arrivée programmée (HHMM)	Reference OTP arrivée
ARR_TIME	Float	Heure arrivée réelle (HHMM)	NaN si annule
ARR_DELAY	Float	Retard arrivée en minutes (négatif = avance)	METRIQUE CIBLE PRINCIPALE - NULL si annule
ARR_DELAY_NEW	Float	Retard arrivée (0 si avance)	Utiliser pour le calcul de l'OTP et les moyennes
ARR_DEL15	Float (0/1)	Indicateur retard arrivée > 15 min (norme DOT)	OTP = 1 - AVG(ARR_DEL15) - SOURCE OFFICIELLE DU KPI
CANCELLED	Float (0/1)	Vol annule (1=oui)	Source de toutes les métriques d'annulation
CANCELLATION_CODE	String	Cause annulation : A=Compagnie B=Meteo C=NAS D=Sécurité	NULL si non annule - 4 codes seulement
DIVERTED	Float (0/1)	Vol détourné (1=oui)	A traiter séparément des retards et annulations
CRS_ELAPSED_TIME	Float	Duree planifiee (minutes)	Reference efficacite de scheduling
ACTUAL_ELAPSED_TIME	Float	Duree reelle (minutes)	NULL si annule
AIR_TIME	Float	Temps de vol effectif (minutes)	< ACTUAL_ELAPSED_TIME - exclut taxi
DISTANCE	Float	Distance vol en miles	Base du calcul des groupes de distance
CARRIER_DELAY	Float	Minutes retard imputable a la compagnie	NULL si non retarde - CAUSE 1/7

Colonne BTS	Type	Description metier	Points de vigilance
WEATHER_DELAY	Float	Minutes retard meteo extreme	NULL si non retarde - CAUSE 2/7
NAS_DELAY	Float	Minutes retard systeme aviation (trafic, meteo moderee)	NULL si non retarde - CAUSE 3/7
SECURITY_DELAY	Float	Minutes retard securite	NULL si non retarde - CAUSE 4/7
LATE_AIRCRAFT_DELAY	Float	Minutes retard avion precedent en retard	NULL si non retarde - CAUSE 5/7

2.4 Les 7 causes de retard distinguées

Les 5 causes BTS officielles sont augmentées de 2 catégories supplémentaires construites depuis les colonnes CANCELLED et DIVERTED, formant ainsi un référentiel complet de 7 motifs de perturbation de vol.

#	Cause	Colonne source	Définition opérationnelle	Responsabilité
1	Carrier Delay	CARRIER_DELAY	Retard imputable à la compagnie : maintenance, équipage, nettoyage, embarquement	Compagnie (contrôlable)
2	Weather Delay	WEATHER_DELAY	Conditions météorologiques extrêmes : tornado, blizzard, ouragan — jugement compagnie	Externe (non contrôlable)
3	NAS Delay	NAS_DELAY	Système aviation national : trafic dense, météo modérée, ops aéroport, ATC	Système/ATC (partiel)
4	Security Delay	SECURITY_DELAY	Evacuation terminal, recontrôle sécurité, file > 29 min aux portiques	Externe (non contrôlable)
5	Late Aircraft Delay	LATE_AIRCRAFT_DELAY	Avion précédent arrive en retard — effet domino entre rotations	Compagnie (semi-contrôlable)
6	Cancellation	CANCELLED + CANCELLATION_CODE	Vol annule (cause A/B/C/D) — absence totale de service	Mixte selon code A/B/C/D
7	Diversion	DIVERTED	Vol détourné vers un aéroport non prévu — service dégradé	Mixte (météo/ops)

→ **Relation entre causes** : Un vol retarde peut cumuler plusieurs causes de retard (ex: CARRIER_DELAY + LATE_AIRCRAFT_DELAY). La somme des 5 causes BTS est égale au ARR_DELAY total pour les vols retardés. Cette propriété est à vérifier systématiquement comme test de cohérence des données.

3. Architecture Pipeline et Jointures Multi-Fichiers

3.1 Le défi spécifique : 10 fichiers annuels hétérogènes

La principale complexité technique de ce projet par rapport aux datasets mono-fichier est la gestion de la concaténation annuelle. Les fichiers BTS sont produits par des exports administratifs annuels dont les schémas peuvent diverger : colonnes ajoutées ou supprimées, renommages (ex: UNIQUE_CARRIER devient OP_UNIQUE_CARRIER), valeurs manquantes systématiques sur certaines années. Un pipeline robuste doit gérer ces divergences de manière déclarative et traçable.

3.2 Requêtage DuckDB multi-années

Une fois les 10 fichiers Parquet générés, DuckDB permet de les interroger comme une table unique via le glob pattern. Les requêtes analytiques comparatives sur 10 ans s'exécutent en quelques secondes sans chargement complet en mémoire.

3.3 Schéma en étoile — Modèles dbt Gold

Modèle dbt	Type	Granularité	Colonnes clés
fact_flights	Faits	1 ligne = 1 vol	flight_key, date_key, carrier_key, origin_key, dest_key, arr_delay, dep_delay, arr_del15, cancelled, cancellation_code, diverted, 5 causes delay (min)
dim_date	Dimension	1 ligne = 1 jour	date_key, year, month, quarter, day_of_week, week, is_weekend, season, economic_period
dim_carrier	Dimension	1 ligne = 1 compagnie	carrier_key, iata_code, carrier_name, carrier_type (Legacy/LCC/ULCC/Regional), active_from, active_to, merged_into
dim_airport	Dimension	1 ligne = 1 aéroport	airport_key, iata_code, airport_name, city, state, hub_tier
dim_route	Dimension	1 ligne = 1 route O-D	route_key, origin_key, dest_key, distance, distance_group
mart_otp_annual	Mart benchmarking	1 ligne = 1 compagnie x année	carrier_key, year, total_flights, otp_pct, avg_arr_delay, cancellation_rate, rank_otp, rank_delta_vs_prev_year
mart_otp_monthly	Mart temporel	1 ligne = 1 compagnie x mois	carrier_key, date_key, otp_pct, avg_arr_delay, total_flights
mart_delay_causes	Mart causes	1 ligne = 1 compagnie x année	carrier_key, year, min_carrier, min_weather, min_nas, min_security, min_late_aircraft, pct_carrier, pct_weather, pct_nas, pct_security, pct_late_aircraft
mart_cancellations	Mart annulations	1 ligne = 1 compagnie x mois x code	carrier_key, date_key, code, count, pct
mart_merger_impact	Mart fusion	1 ligne = 1 compagnie x trimestre	carrier_key, date_key, otp_pct, periode_fusion (pre/during/post), carrier_group_post_merger
mart_benchmarking	Mart comparaison	1 ligne = 1 compagnie x année	OTP rank, delay rank, cancellation rank, score composite, peer_group

4. Axe 1 — Benchmarking OTP et Ranking des Compagnies

AX1 Benchmarking OTP et Ranking des compagnies sur 10 ans

4.1 Enjeux métier

L'On-Time Performance (OTP) est l'indicateur de référence pour mesurer la qualité de service des transporteurs aériens. Il est défini strictement comme la proportion de vols arrivant avec moins de 15 minutes de retard par rapport à l'heure programmée. Puissance de simplification d'un indicateur unique, il cache pourtant une réalité complexe : deux compagnies avec le même OTP de 80% peuvent avoir des profils très différents — l'une annulant peu mais retardant beaucoup, l'autre annulant davantage pour éviter les retards et protéger son OTP.

Sur 10 ans, les écarts de performance entre compagnies sont spectaculaires. Delta Airlines a steadily improved son OTP de 75% en 2010 à plus de 85% en 2018, s'imposant comme le benchmark industriel. Southwest, malgré son modèle point-to-point simplifié, a maintenu une volatilité élevée. Les ultra low-cost (Spirit, Frontier) affichent structurellement les pires performances. Ces divergences sont le cœur de l'axe 1.

4.2 Questions métier à traiter

- Quel est le classement OTP des compagnies sur 10 ans ? Ce classement est-il stable ou volatil ?
- Quelle compagnie a le plus progressé en OTP sur la période ? Laquelle a le plus régressé ?
- L'écart de performance entre la meilleure et la pire compagnie s'est-il réduit ou creuse sur 10 ans ?
- Existe-t-il une corrélation entre la taille de la compagnie (part de marche) et son OTP ?
- Les compagnies qui annulent le plus ont-elles un meilleur OTP (annulation stratégique pour protéger l'OTP) ?
- Quel est le score composite de performance opérationnelle incluant OTP, annulation et retard moyen ?

4.3 Définition technique de l'OTP et ses variantes

Variante OTP	Formule	Colonnes source	Usage métier
OTP standard DOT	% vols avec $ARR_DEL15 = 0$ (non nuls et non annulés)	ARR_DEL15, CANCELLED	KPI officiel DOT - référence réglementaire
OTP strict	% vols avec $ARR_DELAY \leq 0$ (aucune seconde de retard)	ARR_DELAY, CANCELLED	Mesure plus exigeante - benchmark interne compagnie
OTP élargi 30 min	% vols avec $ARR_DELAY \leq 30$	ARR_DELAY, CANCELLED	Vision passager : 30 min = seuil de tolérance réel
OTP annulation incluse	% vols 'parvenus à destination < 15 min' / total vols programmes	ARR_DEL15, CANCELLED	Pénalise les compagnies qui annulent pour protéger leur OTP

Variante OTP	Formule	Colonnes source	Usage métier
OTP départ	% vols avec DEP_DEL15 = 0	DEP_DEL15, CANCELLED	Indicateur d'efficacité opérationnelle au sol

4.4 KPIs et métriques Axe 1

KPI	Formule	Colonnes source	Périodicité
OTP annuel par compagnie	% ARR_DEL15=False sur vols non annulés	ARR_DEL15, CANCELLED, OP_UNIQUE_CARRIER, YEAR	Annuel - base du classement
Rang OTP par année	RANK() OVER (PARTITION BY YEAR ORDER BY OTP DESC)	OTP calcule, YEAR	Annuel - 1er = meilleur
Stabilité du rang	Ecart-type du rang sur 10 ans par compagnie	Rang annuel, OP_UNIQUE_CARRIER	Indicateur de cohérence
Progression OTP	OTP 2018 - OTP 2009 par compagnie (delta absolu)	ARR_DEL15, CANCELLED, YEAR	Annuel - mesure la tendance
CAGR OTP	$(\text{OTP 2018} / \text{OTP 2009})^{(1/9)} - 1$	OTP calcule par année	Taux de croissance annuel composé
Retard moyen conditionnel	AVG(ARR_DELAY) WHERE ARR_DELAY > 0 par carrier x année	ARR_DELAY, OP_UNIQUE_CARRIER, YEAR	Annuel
Taux d'annulation	$\text{SUM}(\text{CANCELLED}) / \text{COUNT}(\ast) \times 100$	CANCELLED, OP_UNIQUE_CARRIER, YEAR	Annuel
Correlation OTP vs volume	Pearson(OTP, nb_vols) sur N compagnies	OTP calcule, COUNT(*), OP_UNIQUE_CARRIER	Annuel - scatter
Score composite perf	$\text{RANK_OTP} \times 0.5 + \text{RANK_CANCEL} \times 0.3 + \text{RANK_DELAY} \times 0.2$	OTP, cancellation_rate, avg_delay - tous dérivés	Annuel - classement multi-critères
Part de marché	$\text{SUM}(\text{vols carrier}) / \text{SUM}(\text{vols total}) \times 100$	OP_UNIQUE_CARRIER, YEAR	Annuel
Ecart top/bottom OTP	OTP meilleure compagnie - OTP pire compagnie	OTP par carrier et par année	Annuel - mesure de la dispersion sectorielle

4.5 Spécifications dashboard Axe 1 — 'Observatoire OTP'

Visualisation	Type	Message métier attendu
Classement OTP annuel	Lollipop chart ou bar horizontal avec benchmark sectoriel	Voir en un coup d'œil qui est au-dessus et en dessous de la moyenne
Bump chart évolution des rangs	Bump chart 10 années x 17-20 compagnies	Visualiser les ascensions et chutes sur la décennie
Progression OTP 2009 vs 2018	Slope chart ou dumbbell	Comparer le point de départ et d'arrivée de chaque transporteur

Visualisation	Type	Message métier attendu
Scatter OTP vs part de marche	Scatter annuel (taille bulle = vols)	Tester la relation taille / ponctualité sur 10 ans
Radar profil compagnie	Spider chart 5 axes (OTP, cancel, delay, retard moyen, diversion)	Vue synthèse d'une compagnie sélectionnée vs moyenne secteur
Heatmap OTP carrier x annee	Heatmap 20 lignes x 10 colonnes	Vision matricielle complète de la performance sur la décennie
Score composite	Bar horizontal classe par score	Classement définitif multicritères de la décennie

5. Axe 2 — Décomposition et Analyse des 7 Causes de Retard

AX2 Décomposition et analyse des 7 causes de retard par transporteur

5.1 Enjeux métier

La décomposition des causes de retard est l'outil le plus puissant pour guider les actions correctives d'une compagnie. Une forte proportion de CARRIER_DELAY (cause 1) signale des défaillances internes contrôlables : maintenance insuffisante, planning équipage trop tendu, temps de turnaround sous-estimes. Elle justifie des investissements en maintenance prédictive et en gestion de crise. A l'inverse, une forte proportion de LATE_AIRCRAFT_DELAY (cause 5) révèle un réseau trop interconnecté ou les retards se propagent en cascade, ce qui appelle une révision du planning de rotations avec plus de slack opérationnel.

Une approche comparative inter-compagnies sur les 7 causes permet d'identifier les 'signatures opérationnelles' de chaque transporteur et de pointer les domaines spécifiques d'amélioration. Elle permet aussi de mesurer l'évolution de ces signatures sur 10 ans — par exemple, une compagnie qui réduit sa part de CARRIER_DELAY de 35% à 20% entre 2009 et 2018 démontre un progrès concret de sa gestion opérationnelle interne.

5.2 Questions métier à traiter

- Quelle est la cause de retard dominante pour chaque compagnie, et est-elle stable sur 10 ans ?
- Les compagnies à fort CARRIER_DELAY ont-elles amélioré cette proportion au fil du temps, signe d'un progrès opérationnel ?
- La part du LATE_AIRCRAFT_DELAY a-t-elle augmenté post-fusions, révélant un réseau plus dense et plus fragile ?
- Les retards NAS sont-ils concentrés sur certains hubs ou certaines périodes, signalant une saturation du système ATC ?
- Les annulations de type A (compagnie) sont-elles corrélées à un fort CARRIER_DELAY — même défaillance, manifestation différente ?
- Quelle est la valeur totale des minutes perdues par cause et par compagnie sur 10 ans (coût système) ?

5.3 KPIs et métriques Axe 2

KPI	Formule	Colonnes source	Grain
Minutes retard par cause (absolues)	SUM(CARRIER_DELAY) etc. par carrier x année	CARRIER_DELAY, WEATHER_DELAY, NAS_DELAY, SECURITY_DELAY, LATE_AIRCRAFT_DELAY	Annuel par compagnie
Part de chaque cause (%)	SUM(cause X) / SUM(toutes causes) x 100 par carrier	Idem - ratio sur total minutes retard	Annuel - stacked 100%
Signature opérationnelle	Profil 5 causes en radar par compagnie	5 colonnes causes, OP_UNIQUE_CARRIER	Annuel - fingerprint
Evolution part CARRIER_DELAY	% CARRIER_DELAY year N - % CARRIER_DELAY 2009 par carrier	CARRIER_DELAY, sum causes, YEAR	Annuel - delta tendance
Ratio retard contrôlable	(CARRIER + LATE_AIRCRAFT) / total minutes retard x 100	CARRIER_DELAY, LATE_AIRCRAFT_DELAY, sum causes	Annuel - levier d'action interne
Retard moyen par cause	AVG(cause X) WHERE cause X > 0 par carrier	Chaque colonne cause, OP_UNIQUE_CARRIER	Annuel - intensité unitaire
Vols retardés par cause	COUNT(vols avec cause X > 0) par carrier	Chaque colonne cause > 0, OP_UNIQUE_CARRIER	Annuel - fréquence
Corrélation annulation type A vs CARRIER_DELAY	Pearson (pct_cancel_A, pct_carrier_delay) sur N carriers	CANCELLED, CANCELLATION_CODE='A', CARRIER_DELAY	Annuel par carrier
Minutes retard NAS par aeroport hub	SUM(NAS_DELAY) GROUP BY ORIGIN x YEAR	NAS_DELAY, ORIGIN, YEAR	Annuel - saturation hub
Part LATE_AIRCRAFT pre vs post fusion	% LATE_AIRCRAFT avant / après date fusion pour carriers fusionnées	LATE_AIRCRAFT_DELAY, sum causes, YEAR, carrier_group_post_merger	Avant/après fusion

5.4 Interprétation métier des causes — guide de lecture

Cause dominante	Interprétation opérationnelle	Action recommandée	Levier d'action
CARRIER_DELAY > 40%	Défaillances internes : maintenance réactive, planning équipage tendu, temps de turnaround sous-estimes	Investir en maintenance prédictive, réviser les marges de planning	Contrôlable - interne
LATE_AIRCRAFT > 35%	Réseau trop dense ou trop optimiste : les retards se propagent en cascade entre rotations	Ajouter des marges de slack entre rotations, créer des vols 'tampon'	Semi-contrôlable
NAS_DELAY > 30%	Saturation des hubs opérées : trop de vols concentres aux heures de pointe, coordination ATC difficile	Redistribuer les départs sur des créneaux moins charges	Partiel - négocie avec ATC
WEATHER_DELAY > 20%	Forte exposition aux conditions extrêmes : hubs dans des zones météorologiquement risquées	Diversifier le réseau, plans de contingence météo systématiques	Non contrôlable

Cause dominante	Interprétation opérationnelle	Action recommandée	Levier d'action
Annulations type A > 2%	Fragilité opérationnelle interne : manque de personnels, parc insuffisant pour les substitutions	Renforcer les réserves d'équipages et la flotte de backup	Contrôlable - interne

5.5 Spécifications dashboard Axe 2 — 'Anatomie des Retards'

Visualisation	Type	Message métier attendu
Stacked bar 100% causes par compagnie	Stacked bar horizontal 100%	Signature opérationnelle de chaque transporteur en un visuel
Heatmap carrier x cause x année	Heatmap 3D aplatie	Détecter quand une cause a explosé pour une compagnie donnée
Evolution part CARRIER_DELAY	Multi-line chart par carrier	Mesurer les progrès ou régressions sur la contrôlabilité
Ratio retard contrôlable vs externe	Bar groupe 2 barres par carrier	Distinguer ce qui dépend de la compagnie vs l'environnement
Minutage total par cause sectoriel	Treemap ou Sunburst	Quantifier le poids système de chaque cause sur 10 ans
Corrélation annulation A vs CARRIER	Scatter par carrier x année	Valider l'hypothèse 'annulation comme stratégie anti-retard'
Zoom cause sur compagnie sélectionnée	Bar évolution mensuelle par cause	Diagnostiquer un problème saisonnier ou ponctuel

6. Axe 3 — Impact des Fusions et de la Consolidation Sectorielle

AX3 Impact des fusions et de la consolidation sectorielle sur la performance

6.1 Enjeux métier

La décennie 2009-2018 est celle des méga-fusions dans l'aviation américaine. Ces consolidations ont réduit le nombre de compagnies significatives de plus d'une douzaine à quatre grands groupes dominant 80% du marché (American, Delta, United, Southwest). Chaque fusion est suivie d'une période d'intégration opérationnelle — harmonisation des flottes, des systèmes informatiques, des conventions collectives — qui se traduit presque systématiquement par une dégradation transitoire de l'OTP avant une phase de stabilisation.

L'analyse de l'impact des fusions sur la performance constitue un cas d'étude métier exceptionnel : il est rare de disposer de données longitudinales couvrant l'avant, le pendant et l'après d'un évènement sectoriel majeur. Ce type d'analyse est exactement ce que réalisent les analystes des agences de notation ou des banques d'investissement couvrant le secteur aéronautique.

6.2 Chronologie des fusions à analyser

Fusion	Date effective	Codes IATA avant	Code après	Période d'intégration
United Airlines + Continental Airlines	Octobre 2010	UA (United) + CO (Continental)	UA	2010-2013 (SAP migration 2012)

Fusion	Date effective	Codes IATA avant	Code après	Période d'intégration
Southwest Airlines + AirTran Airways	Mai 2011	WN (Southwest) + FL (AirTran)	WN	2011-2015 (intégration progressive)
American Airlines + US Airways	Décembre 2013	AA (American) + US (US Airways)	AA	2013-2015 (code sharing puis intégration)
Alaska Airlines + Virgin America	Décembre 2016	AS (Alaska) + VX (Virgin America)	AS	2016-2018 (hors période - référence post)

! Attention codes IATA post-fusion : Après une fusion, l'une des compagnies cesse de reporter sous son ancien code IATA. Les vols de Continental (CO) disparaissent des données à partir de 2012 et sont intégrés dans UA. De même, AirTran (FL) disparaît progressivement entre 2012 et 2015. La dimension `dim_carrier` doit gérer ces transitions avec les colonnes `active_from`, `active_to` et `merged_into`.

6.3 Questions métier à traiter

- Pour chaque fusion, peut-on observer une dégradation de l'OTP dans les 4 trimestres suivant la date effective ?
- La fusion United+Continental a-t-elle généré plus de retards `CARRIER_DELAY` pendant la période d'intégration SAP (2012) ?
- La consolidation du secteur (4 majors contrôlant 80% du trafic) a-t-elle amélioré ou dégradé la ponctualité globale ?
- Les compagnies qui ont fusionné ont-elles récupéré un OTP supérieur à leur moyenne pré-fusion dans les 3 ans suivant l'intégration ?
- L'effet domino (`LATE_AIRCRAFT`) s'est-il amplifié après les fusions, les réseaux étant plus denses et interconnectés ?

6.4 KPIs et métriques Axe 3

KPI	Formule	Colonnes source	Grain temporel
OTP pré-fusion (baseline)	AVG(OTP) sur 4 trimestres avant date fusion par carrier	ARR_DEL15, CANCELLED, OP_UNIQUE_CARRIER, FL_DATE	Trimestriel - fenêtre -4T à -1T
OTP pendant intégration	AVG(OTP) sur 4 trimestres post-fusion	Idem - fenêtre +1T à +4T	Trimestriel - fenêtre +1T à +4T
OTP post-stabilisation	AVG(OTP) sur années 3-5 post-fusion	Idem - fenêtre +3 à +5 ans	Annuel - récupération
Delta OTP fusion	OTP post-intégration - OTP pré-fusion	OTP calculé par carrier x trimestre	Delta par étape
Part <code>CARRIER_DELAY</code> pendant intégration	% <code>CARRIER_DELAY</code> sur période d'intégration	<code>CARRIER_DELAY</code> , <code>sum causes</code> , <code>carrier</code> , <code>period</code>	Trimestriel

KPI	Formule	Colonnes source	Grain temporel
Part LATE_AIRCRAFT pré vs post fusion	% LATE_AIRCRAFT avant vs après par carrier fusionne	LATE_AIRCRAFT_DELAY, sum causes, YEAR, carrier	Avant/après annuel
Volume de vols pré/post fusion	COUNT(*) par carrier par trimestre	OP_UNIQUE_CARRIER, FL_DATE	Trimestriel - mesure la croissance
Concentration marche (HHI proxy)	SUM((part_marche_carrier)^2) par année	COUNT vols par carrier / total, YEAR	Annuel - indice Herfindahl
OTP moyen sectoriel	AVG(OTP) toutes compagnies, pondération volume	ARR_DEL15, CANCELLED, YEAR	Annuel - trend global

6.5 Spécifications dashboard Axe 3 — 'Décennie de Consolidation'

Visualisation	Type	Message metier attendu
Timeline fusions annotée	Line OTP + annotations évènements	Relier visuellement les dates de fusion aux variations d'OTP
Comparaison OTP avant/après fusion	Bullet chart avant/pendant/après par carrier	Quantifier la dégradation et la récupération pour chaque fusion
Nombre de compagnies actives par année	Bar décroissante annotée	Visualiser la consolidation progressive du secteur
OTP moyen sectoriel sur 10 ans	Area chart avec annotations	Montrer la tendance de fond malgré les perturbations de fusion
Evolution LATE_AIRCRAFT pour carriers fusionne	Multi-line chart	Tester l'hypothèse réseau plus dense = plus de cascade
Indice de concentration (HHI)	Line chart secondaire	Corr OTP global avec niveau de consolidation sectorielle

7. Axe 4 — Saisonnalité, Cycles Economiques et Patterns Long Terme

AX4

Saisonnalité, cycles économiques et patterns de ponctualité long terme

7.1 Enjeux métier

Dix ans de données permettent une analyse saisonnière et cyclique impossible avec des datasets courts. La saisonnalité aéronautique est double : un cycle court annuel (pic été de trafic avec orages convectifs, tempêtes hivernales décembre-janvier) et un cycle long qui suit les cycles économiques (récession 2009, croissance 2014-2018). La décomposition STL sur 10 ans de données mensuelles permet d'isoler ces deux composantes avec une précision inédite.

De plus, la granularité hebdomadaire et horaire révèle des patterns comportementaux stables : le jeudi est historiquement le pire jour de la semaine pour les retards (cumul des perturbations de la semaine), tandis que le mercredi matin offre les meilleures conditions de ponctualité. Ces patterns aident les voyageurs fréquents et les planificateurs de vols a optimiser leurs choix.

7.2 Questions métier à traiter

- Quels sont les mois structurellement les plus difficiles pour la ponctualité, et est-ce cohérent avec les types de retards dominants (météo vs NAS) ?
- La saisonnalité est-elle stable sur 10 ans ou certaines années ont-elles rompu le pattern attendu ?
- Quel est le meilleur et le pire jour de la semaine pour voyager, et cela varie-t-il selon la compagnie ?
- Y a-t-il une corrélation entre le prix du kérosène (proxy : année 2014-2016 = bas prix) et l'OTP moyen sectoriel ?
- Les retards de type NAS ont-ils une saisonnalité différente des retards CARRIER (l'été favorise NAS, l'hiver favorise CARRIER) ?
- Quel est le meilleur créneau horaire de départ pour minimiser le risque de retard ?

7.3 KPIs et métriques Axe 4

KPI	Formule	Colonnes source	Grain
OTP par mois (agregat 10 ans)	AVG(OTP) GROUP BY MONTH sur toutes années	ARR_DEL15, CANCELLED, MONTH	Mensuel - pattern saisonnier pur
OTP par mois x année	AVG(OTP) GROUP BY YEAR, MONTH	ARR_DEL15, CANCELLED, YEAR, MONTH	Heatmap 10x12
Décomposition STL du retard moyen	Serie mensuelle AVG(ARR_DELAY) décomposée	ARR_DELAY, FL_DATE agrégé mensuel	Signal mensuel sur 10 ans
Indice saisonnier par mois	IS = CA mois / (CA annuel / 12)	ARR_DELAY ou OTP agrégé	Mensuel - IS > 1 = mois difficile
OTP par jour de la semaine	AVG(OTP) GROUP BY DAY_OF_WEEK	ARR_DEL15, CANCELLED, DAY_OF_WEEK	Hebdomadaire - pattern 10 ans
OTP par créneau horaire départ	AVG(OTP) GROUP BY floor(CRS_DEP_TIME/100)	ARR_DEL15, CANCELLED, CRS_DEP_TIME	Horaire - conseils voyageur
Saisonnalité cause WEATHER	SUM(WEATHER_DELAY) par MONTH agrégé 10 ans	WEATHER_DELAY, MONTH	Mensuel - pic hiver vs ete
Saisonnalité cause NAS	SUM(NAS_DELAY) par MONTH agrégé 10 ans	NAS_DELAY, MONTH	Mensuel - pic ete vs hiver
Corrélation OTP vs cycle économique	Pearson (OTP annuel, GDP_growth) — donnée externe	OTP calcule, YEAR + donnée macro externe	Annuel
Tendance long terme OTP	Régression linéaire OTP = f(YEAR)	OTP annuel sectoriel	Annuel - 10 ans
Volatilité saisonnière par carrier	Ecart-type OTP mensuel par carrier	OTP mensuel, OP_UNIQUE_CARRIER	Annuel - stabilité

7.4 Périodisation économique et contexte externe

Période	Contexte macro	Indicateur externe suggère	Impact attendu sur OTP
2009	Récession - trafic -7%, consolidations	GDP growth = -2.5%	OTP stable ou améliore (moins de vols = moins de congestion)
2010-2012	Rebond + fusions (UA+CO, WN+FL)	GDP growth +2-3%	OTP volatil - perturbations d'intégration
2013	Fusion AA+US Airways - année critique	Nb faillites secteur = 0	Dégradation transitoire AA et US
2014-2016	Bas prix kérosène (-50%), rentabilité maximale	Prix baril WTI = 30-60 USD	Hausse OTP - réinvestissement opérationnel
2017-2018	Croissance trafic +4%/an, saturation hubs	Taux remplissage >85%	Pression NAS et LATE_AIRCRAFT

7.5 Spécifications dashboard Axe 4 — 'Cycles & Saisonnalité'

Visualisation	Type	Message métier attendu
Heatmap OTP année x mois	Heatmap 10 lignes x 12 colonnes	Voir d'un seul coup d'œil les mois difficiles de chaque année
Décomposition STL mensuelle	Multi-line chart 3 composantes	Isoler la tendance structurelle de la cyclicité saisonnière
Calendrier annuel type (pattern moyen)	Polar bar ou bar mensuel 1-12	La saisonnalité pure indépendante de l'année
OTP par jour de la semaine	Heatmap 7 jours x 10 ans	Confirmer la stabilité du pattern hebdomadaire
OTP par heure de départ	Bar horaire 0h-23h	Guide pratique : meilleur créneau pour minimiser le risque
Trend linéaire OTP sectoriel	Scatter + droite regression	Confirmer ou infirmer la tendance d'amélioration long terme
Contexte macro annote	Dual-axis line OTP + context	Corr visuelle OTP avec évènements économiques

8. Stack Technique

La stack ci-dessous est représentative, elle couvre l'intégralité du cycle de vie de la donnée. Cependant vous pouvez utiliser la stack de votre choix.

Catégorie	Outil	Version	Rôle spécifique dans ce projet
Versionning	Git + GitHub	Git 2.x	Commits sémantiques, PRs, code review
Langage	Python	3.10+	Orchestration pipeline, scripting ETL
Data Processing standard	Pandas	2.0+	EDA sur 1 fichier annuel, prototypage
Data Processing Big Data	Polars	0.20+	Audit schémas, conversion CSV → Parquet, concaténation robuste
Format colonnaire	PyArrow / Parquet	14+	Stockage ZSTD partitionne par année
Moteur OLAP	DuckDB	0.10+	Requêtes SQL analytiques sur 10 fichiers Parquet unifiés
Transformations SQL	dbt-core + dbt-duckdb	1.7+	11 modèles Gold, tests, docs
Profiling	ydata-profiling	4.x	Rapport qualité sur 1 année représentative (2015)
Analyse temporelle	Statsmodels	0.14+	Décomposition STL sur série mensuelle 10 ans
Visualisation EDA	Plotly	5.x	Notebooks interactifs par axe
Notebooks	Jupyter Lab	4.x	1 notebook par axe + 1 profiling + 1 audit schémas
Dashboard	Power BI Desktop	Latest	Observatoire final 5 pages
Alternative	Apache Superset	Latest	Connecte nativement DuckDB, gratuit
Config	python-dotenv	Latest	Variables d'environnement, chemins
Orchestration	Makefile	GNU Make	make run = pipeline complet en 1 commande

9. Livrables

Ref.	Livrable	Format	Criteres de validation
L1	Rapport de profiling sur année 2015	Notebook HTML exporté	100% colonnes, distributions retards, outliers, taux nuls par cause
L2	Rapport d'audit schemas multi-annuels	schema_audit.json + section DECISIONS.md	Divergences documentées, colonnes manquantes signalées, stratégie de normalisation justifiée
L3	Scripts conversion CSV → Parquet (10 années)	Python src/conversion/modules .py	Idempotents, harmonisation IATA gérée, schéma Parquet unifié documenté
L4	Scripts nettoyage Silver	Python modules .py	Colonnes dérivées présentes, cohérence somme causes vs ARR_DELAY vérifiée
L5	dim_carrier avec gestion des fusions	Fichier seeds/ dbt + doc YAML	Chaque compagnie avec carrier_type, active_from/to, merged_into renseigné
L6	Projet dbt Gold complet	Repertoire dbt/ dans Git	dbt test 100% vert, 11 modèles, docs générés avec lineage
L7	Dictionnaire de données	Markdown ou Excel	Toutes colonnes Silver et Gold avec source BTS, type et calcul documentés
L8	Notebooks EDA (5 notebooks)	Jupyter Lab .ipynb	1 notebook par axe + audit schémas, cellules annotées, Plotly interactifs
L9	Dashboard Observatoire final	Fichier .pbix ou Superset	5 pages (exec + 4 axes), filtres carrier/année/période économique
L10	Rapport d'analyse et recommandations	PDF 8 à 12 pages	3 recommandations par axe, chiffrées
L11	Depot Git structure + Makefile	GitHub / GitLab	make run reproductible depuis les CSV, README complet, commits sémantiques
L12	Présentation orale + demo live	PowerPoint 20 min	Demo Dashboard live, 1 insight marquant par axe